Застосування математичного моделювання для прогнозування відтоку клієнтів в онлайн-гемблінгу

Аналіз наукової статті: «Churn Prediction in Online Gambling»
(Merchie & Ernst, 2022)

15 лютого 2026 р.

1 Постановка задачі

1.1 Бізнес-проблема

Онлайн-казино стикаються з проблемою втрати клієнтів (customer churn) — ситуації, коли гравці припиняють використовувати платформу. У дослідженні розглядається кейс бельгійської компанії Gaming1, яка визначає гравця як «churner», якщо протягом **35 днів** не було жодної активності.

Як зазначалося на лекції, математичне моделювання дозволяє *«описати лише ті аспекти, які є ключовими для вирішення конкретної задачі»*. Основна мета моделі — **прогнозувати ймовірність відтоку гравця протягом наступних 30 днів**, що дозволяє заздалегідь планувати retention-кампанії та оптимізувати маркетинговий бюджет.

1.2 Формалізація проблеми

Об'єкт моделювання: Динаміка зміни поведінки онлайн-гравця в часі та її зв'язок з ймовірністю припинення гри.

Що моделюється: Складні темпоральні залежності між історією активності гравця (кількість ігор, депозити, частота входів) та його майбутнім рішенням припинити використання платформи. Модель «навчається» виявляти патерни згасання активності, які передують відтоку.

Задача формалізується як **бінарна класифікація часових рядів**: для кожного гравця p у момент t потрібно передбачити:

$$y_t^p = \begin{cases} 1, & \text{якщо гравець відтече протягом наступних 30 днів} \\ 0, & \text{якщо залишиться активним} \end{cases} \tag{1}$$

Вхідні дані: Багатовимірні часові ряди $X^p = \{x_0^p, x_1^p, \ldots, x_t^p\}$, де кожен вектор $x_i^p \in \mathbb{R}^8$ містить щоденну агреговану інформацію: кількість ігор у казино, кількість спортивних ставок, кількість депозитів та виведень коштів, кількість входів на сайт, Gross Gaming Revenue від казино та спорту, кількість днів без активності.

Модель: Функція $h_t : \mathbb{R}^{60\times 8} \to [0, 1]$, що відображає історію останніх 60 днів у ймовірність відтоку:

$$P(y_t^p = 1) = h_t(X_{t-59:t}^p) \tag{2}$$

де $X_{t-59:t}^p$ — матриця розміром 60×8 (60 днів історії, 8 характеристик щодня).

2 Математичні підходи

2.1 Класифікація моделі за критеріями

Згідно з класифікацією, розглянутою на лекції, модель характеризується так:

За невизначеністю: стохастична модель. Поведінка гравців містить випадковий шум, використовується стохастичний градієнтний спуск (RMSprop). Це відрізняється від детермінованих моделей (як-от модель руху планет з лекції).

За методом розв'язку: чисельна модель. Аналогічно до кліматичних моделей з лекції, задача не має аналітичного розв'язку і потребує ітеративної оптимізації через 20 епох навчання — тобто 20-кратного проходу через датасет (793,779 зразків), під час якого модель поступово покращує параметри методом градієнтного спуску.

За часовою дискретизацією: дискретна модель. Подібно до моделі AR(1) з лекції, дані агреговані по днях, а не описуються диференціальними рівняннями.

2.2 Рекурентні нейронні мережі як реалізація моделі

Архітектура моделі: Функція h_t реалізується через **рекурентну нейронну мережу (RNN)** — клас архітектур, здатних обробляти послідовні дані та виявляти темпоральні залежності.

Принцип роботи: На відміну від звичайних нейронних мереж, RNN обробляє часовий ряд крок за кроком, підтримуючи прихований стан h_t, який «запам'ятовує» важливу інформацію з попередніх днів:

$$h_i = f(h_{i-1}, x_i; \theta), \quad i = t - 59, \ldots, t \tag{3}$$

де h_0 — початковий стан (нульовий вектор), θ — параметри мережі (ваги), що навчаються. Фінальна ймовірність відтоку обчислюється як:

$$P(y_t^p = 1) = \sigma(W \cdot h_t + b) \tag{4}$$

де $\sigma(z) = \frac{1}{1+e^{-z}}$ — sigmoid функція, W, b — параметри вихідного шару.

Що моделює RNN: Мережа автоматично виявляє складні паттерни, наприклад: поступове зменшення депозитів ($\$100 \to \$50 \to \$20$), збільшення перерв між сеансами (щодня $\to$ раз на 3 дні $\to$ раз на тиждень), зміну типу активності (казино + спорт $\to$ тільки спорт $\to$ нічого). Ці паттерни не формалізуються простими правилами, але модель «навчається» з даних.

Використано архітектуру **LSTM** (Long Short-Term Memory): $\text{LSTM}_{128} \to \text{LSTM}_{64} \to \text{sigmoid}_1$. LSTM вирішує проблему зникаючого градієнта через спеціальні механізми контролю інформаційного потоку, що дозволяє ефективно запам'ятовувати залежності на інтервалі 60 днів.

Архітектура	Точність	Precision	Recall
LSTM	83.4%	61.6%	**61.1%**
GRU	**83.7%**	63.6%	57.5%
nBRC	83.1%	**64.4%**	48.6%

Таблиця 1: Порівняння ефективності різних RNN-архітектур

Функція втрат — **бінарна крос-ентропія**:

$$H(y_t^p, h_t(i_t^p)) = -\left(y_t^p \log h_t(i_t^p) + (1 - y_t^p) \log(1 - h_t(i_t^p))\right) \tag{5}$$

Оптимізація через **RMSprop** — адаптивний метод градієнтного спуску з параметрами: міні-батч 256 зразків, швидкість навчання $\alpha = 10^{-3}$, 20 епох.

3 Висновки

3.1 Ефективність математичного моделювання

Дослідження демонструє високу ефективність застосування математичних методів:

1. **Точність прогнозування:** accuracy 83.4–83.7% — відмінний результат для задачі з дисбалансом класів (22% churners).

2. **Гнучкість підходу:** різні архітектури оптимізують різні метрики залежно від бізнес-пріоритетів (nBRC для precision, LSTM для recall, GRU для балансу). Для гемблінгу пріоритетним є Recall (реалізований в LSTM), оскільки фінансові втрати від неідентифікованого відтоку (LTV гравця) значно перевищують витрати на маркетингову комунікацію з помилково визначеним сегментом.

3. **Стабільність у часі:** модель зберігає ефективність протягом місяців без перенавчання, що критично для практичного використання.

Як підкреслювалося на лекції, математичне моделювання «дозволяє спростити аналіз складних систем». Подібно до епідеміологічної моделі SIR (приклад з лекції), модель прогнозування churn перетворює бізнес-проблему на конкретну, вимірювану задачу.

3.2 Практичне значення та економічний ефект

Модель ідентифікує гравців з високим ризиком за 30 днів до події, що дозволяє проводити таргетовані retention-кампанії. Розглянемо ілюстративний розрахунок економічного ефекту.

Вихідні дані (з результатів моделі та типових показників індустрії):

- База гравців: 10,000 осіб
- Відсоток churners (з статті): 22%
- Recall моделі LSTM (з статті): 61.1%
- Середній LTV гравця: $500 (типове припущення для онлайн-гемблінгу)
- Вартість retention-кампанії: $10 на гравця (бонус/промо)
- Конверсія retention-кампанії: 20% (консервативна оцінка)

Покроковий розрахунок:

$$
\begin{aligned}
\text{1. Реальна кількість churners} &= 10{,}000 \times 0.22 = 2{,}200 \text{ гравців} \\
\text{2. Виявлено моделлю (recall 61\%)} &= 2{,}200 \times 0.611 = 1{,}344 \text{ гравці} \\
\text{3. Проведено кампаній} &= 1{,}344 \text{ (на всіх виявлених)} \\
\text{4. Успішно утримано (20\% конверсія)} &= 1{,}344 \times 0.20 = 269 \text{ гравців} \\
\text{5. Дохід від утриманих} &= 269 \times \$500 = \$134{,}500 \\
\text{6. Витрати на кампанії} &= 1{,}344 \times \$10 = \$13{,}440 \\
\text{7. Чистий ефект} &= \$134{,}500 - \$13{,}440 = \$121{,}060
\end{aligned}
$$

Обмеження розрахунку: Це ілюстративний приклад. Реальні показники (LTV, вартість кампанії, конверсія) варіюються залежно від сегмента гравців та типу retention-заходів. За даними Harvard Business Review [2], залучення нового клієнта коштує у 5–25 разів дороже утримання існуючого, що робить подібні моделі економічно вигідними навіть при помірній точності.

3.3 Обмеження моделі

Як підкреслювалося на лекції про важливість припущень, модель має обмеження:

Технічні:

1. дисбаланс класів ускладнює навчання (22% churners в тестових даних);
2. чутливість до одноразових подій (зміна правил, технічні збої);
3. потреба в мінімум 60 днях історії;
4. припущення стаціонарності порушується при зміні конкурентного середовища або запуску нових ігор.

Бізнес-обмеження: модель не враховує цінність клієнта (VIP vs casual), що знижує економічну ефективність retention-кампаній.

Зовнішні фактори: сезонність, макроекономіка, регуляторні зміни, якість сервісу.

Підсумок

Модель органічно поєднує всі типи класифікацій — стохастична (випадковість у даних), чисельна (без аналітичного розв'язку), дискретна (щоденна агрегація).

Точність 83.4% та ілюстративний економічний ефект понад $130,000 демонструють, що математичне моделювання — потужний інструмент створення конкурентних переваг. Водночас, висвітлення обмежень підкреслює необхідність людського контролю при прийнятті остаточних рішень.

Використання RNN для виявлення темпоральних патернів ілюструє силу математичного апарату: те, що неможливо формалізувати простими правилами, модель навчається з даних.

Література

[1] Merchie, F., & Ernst, D. (2022). Churn prediction in online gambling. *arXiv preprint arXiv:2201.02463*.

[2] Gallo, A. (2014). The Value of Keeping the Right Customers. *Harvard Business Review*. Retrieved from `https://hbr.org/2014/10/the-value-of-keeping-the-right-customers`

[3] Чернятевич, А. А. (2024). Вступ до моделювання процесів. Лекція 1.